

### Likelihood funktion

Givet data  $y = (y_1 \dots y_n)^T$  og en parametrisk model  $f_Y(y; \theta)$ ,  $\theta \in \Theta^k$ , så er likelihoodfunktionen enhver funktion på formen

$$L(\theta, y) = c(y)f_Y(y, \theta) \quad (1)$$

hvor  $c(y) > 0$  ikke afhænger af  $\theta$ .

### Normaliseret likelihood

$$L_{norm}(\theta, y) = \frac{f_Y(y; \theta)}{\sup_{\theta} f_Y(y; \theta)}$$

### Log-likelihood

$$l(\theta; y) = \log L(\theta; y)$$

### Maksimum likelihood

Givet  $Y = y$ , så siges maksimum likelihood estimeret (MLE)  $\hat{\theta}(y) = \hat{\theta}$  at eksistere, hvis det er det entydige maksimum til  $L(\theta, y)$ .

### Eksistens af MLE

Givet  $E = \{y : \hat{\theta}(y) \text{ eksisterer}\}$ . Hvis  $P(Y \in E) = 1$  for alle  $\theta \in \Theta^h$ , så er  $\hat{\theta}(Y)$  maksimum likelihood estimatoren.

### Bemærk

- Hvis  $\hat{\theta} \in \text{int } \Theta^k$  (indre punkt), så kan MLE findes som en løsning til ligningen  $\frac{\partial}{\partial \theta} l(\theta; y) = 0_{k \times 1}$ .
- Husk at tjekke om det rent faktisk er et maksimum, dvs  $\frac{\partial^2}{\partial \theta \partial \theta^T} l(\theta; y) = 0_{k \times k}$ .

### Sufficient statistik

$t(y_1, \dots, y_n)$  er en sufficient statistik for  $\theta$ , hvis

$$f_Y(y; \theta) = h(y)g(t(y); \theta) \quad (2)$$

hvis  $h$  ikke afhænger af  $\theta$  og  $g$  kun afhænger af  $y$  gennem  $t(y)$ .

### Eksempel 2.4 + 2.5

Tre flasker fyldes til 700ml.

$y$  = for meget fyldt i: (4.6; 6.3; 5.0).

$\mu$  = hvor meget overfyldes de i middel

Opstil model:

$$Y_i = \mu + \varepsilon_i \quad (3)$$

Antag  $Y_i$  uafhængige af hinanden,  $Y_i \sim N(\mu, \sigma^2)$ , og  $\sigma^2 = 1$ ,  $\mu$  ukendt,  $\theta = \mu$ .

Tæthed af model:

$$f_Y(y; \mu) = \prod_{i=1}^3 \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(y_i - \mu)^2}{2}\right) \quad (4)$$

Likelihood:

$$L(\mu; y) = \left(\frac{1}{\sqrt{2\pi}}\right)^3 \exp\left(-\frac{\sum(y_i - \bar{y})}{2}\right) \exp\left(-\frac{n(\bar{y} - \mu)^2}{2}\right) \quad (5)$$

hvor  $\bar{y} = \frac{\sum y_i}{n}$ .

Ved brug af ovenstående metode til at finde MLE, så fås

$$\text{MLE} = \mu = \bar{y} = 5.3 \quad (6)$$

Dette er det bedste gæt vi har efter tre opfyldninger.

Der haves desuden en sufficient statistik:

$$t(y) = \bar{y} \quad (7)$$

for  $\mu$ .

### Skore funktion

Lad  $\theta = (\theta_1, \dots, \theta_k) \in \Theta^k$ , antag  $\Theta^k$  er en åben mængde, og at log-likelihood funktionen er kontinuert differentiabel. Skore funktionen er da

$$S(\theta, y) = \frac{\partial}{\partial \theta} L(\theta; y) = \begin{pmatrix} \frac{\partial}{\partial \theta_1} l(\theta; y) \\ \vdots \\ \frac{\partial}{\partial \theta_k} l(\theta; y) \end{pmatrix} \quad (8)$$

Under regularitetsantagelser

$$E_\theta \left[ \frac{\partial}{\partial \theta} l(\theta; y) \right] = 0_{k \times 1} \quad (9)$$

### Informationsmatrix

Observeret information:

$$j(\theta; y) = -\frac{\partial^2}{\partial \theta \partial \theta^T} l(\theta; y) \quad (10)$$

Forventet information:

$$i(\theta) = E_{\theta} [j(\theta; Y)] \quad (11)$$

Under regularitetsantagelser er den forventede information og Fisher informationen den samme, det vil sige

$$\begin{aligned} i(\theta) &= E_{\theta} \left[ \frac{\partial^2}{\partial \theta \partial \theta^T} l(\theta; Y) \right] \\ &= E_{\theta} \left[ \frac{\partial}{\partial \theta} l(\theta; Y) \left( \frac{\partial}{\partial \theta} l(\theta; Y) \right)^T \right] \end{aligned}$$

*Bevis*

Skriv en nulmatrix på en besværlig måde:

$$\begin{aligned} 0_{k \times k} &= \frac{\partial^2}{\partial \theta \partial \theta^T} \int f_Y(y; \theta) dy = \int \frac{\partial^2}{\partial \theta \partial \theta^T} f_Y(y; \theta) dy \\ &= \int \frac{\partial}{\partial \theta} \left( \frac{\partial \log f_Y(y; \theta)}{\partial \theta} f_Y(y; \theta) \right) dy \\ &= \int \left( \frac{\partial^2}{\partial \theta \partial \theta^T} \log f_Y(y; \theta) \right) f_Y(y; \theta) dy + \int \frac{\partial \log f_Y(y; \theta)}{\partial \theta} \frac{\partial \log f_Y(y; \theta)}{\partial \theta^T} f_Y(y; \theta) dy \\ &= E_{\theta} \left[ \frac{\partial^2}{\partial \theta \partial \theta^T} l(\theta, Y) \right] + E_{\theta} \left[ \frac{\partial l(\theta; Y)}{\partial \theta} \left( \frac{\partial l(\theta; Y)}{\partial \theta} \right)^T \right] \end{aligned}$$

Bemærk:  $j(\theta; y) \geq 0_{k \times k}$  for MLE

## Eksempel 2.6

Likelihood funktion:

$$L(\mu; y) = c(y) \exp \left( -\frac{n(\bar{y} - \mu)^2}{2} \right) \quad (12)$$

Log-lik funktion:

$$l(\mu; y) = -\frac{n(\bar{y} - \mu)^2}{2} + \text{konstant} \quad (13)$$

Skore funktion:

$$S(\mu; y) = n(\bar{y} - \mu) \quad (14)$$

Obersveret information:

$$j(\mu; y) = n \quad (15)$$

Forventet information:

$$i(\mu) = E [j(\mu; y)] = E[n] = n \quad (16)$$

Generelt er  $j(\theta; y)$ ,  $j(\theta; Y)$  og  $i(\theta)$  ikke ens.

### Reparametrisering

$\psi = h(\theta)$  er en bijektiv funktion fra  $\Theta^k$  til  $\Psi^k$ .  $Y$  er en omparametrisering af  $\theta$ .

$$L_{\Psi}(\psi; y) = L(h^{-1}(\psi); y) \quad (17)$$

### Invariants

Antag  $\hat{\theta}$  er MLE for  $\theta$ , og  $\psi = h(\theta)$  være en bijektiv afbildning fra  $\Theta^k$  til  $\Psi^k$ . Så er  $\hat{\psi} = h(\hat{\theta})$  MLE for  $\psi = h(\theta)$ .

*Bevis*

$$\sup_{\psi} L_{\Psi}(\psi; y) = \sup_{\psi} L(h^{-1}(\psi); y) = \sup_{\theta} L(\theta; y)$$